

机器学习（本科生公选课）GEC6531

第3节 逻辑回归 Logistic Regression

计算机科学与技术学院

张瑞 教授

邮箱: ruizhang6@hust.edu.cn

签到 & 思考

■ 微助教签到（学校要求）

1. 加入课堂：微信扫码或者通过微助教公众号



课堂名称: GEC6531 机器学习 (公选课)
课堂编号: OA628

1、扫码关注公众号: 微助教服务号。
2、点击系统通知: “[点击此处加入【GEC6531 机器学习 \(公选课\)】课堂](#)”, 填写学生资料加入课堂。

*如未成功收到系统通知, 请点击公众号下方“学生” - “全部(A)” - “加入课堂” --- “输入课堂编号”手动加入课堂

二维码有效期至: 2024-11-16

2. 微信扫码签到

线性规划中用最大似然估计
(MLE) 求参的矩阵理解

今天的目录

■ 逻辑回归

- 分类问题
- 逻辑回归的表示
- 决策边界

■ 逻辑回归求解

- 损失函数
- 用最大似然估计 (MLE) 求参
- 用最大后验估计 (MAP) 求参
- 正则化
- 梯度下降

今天的目录

■ 逻辑回归

- 分类问题
- 逻辑回归的表示
- 决策边界

■ 逻辑回归求解

- 损失函数
- 用最大似然估计 (MLE) 求参
- 用最大后验估计 (MAP) 求参
- 正则化
- 梯度下降


分类问题

- 是否垃圾邮件
- 是否诈骗电话
- 是否下雨

$$y \in \{0, 1\}$$

0: “阴性” (例如: 不是垃圾邮件、不是诈骗电话、不下雨等)
1: “阳性” (例如: 是垃圾邮件、是诈骗电话、下雨等)

用线性回归解决分类问题



■ 通过阈值来分类

- 如果 $h(x) \geq 0.5$, 预测 $y=1$
- 如果 $h(x) < 0.5$, 预测 $y=0$

线性回归分类的值域问题

■ 分类

- $y = 0$ 或者 1
- 但是 $h(x)$ 可能 >1 或者 <0 , 希望 $0 \leq h(x) \leq 1$


■ 逻辑回归

- Logistic regression: $0 \leq h(x) \leq 1$

名字叫逻辑回归是历史原因, 但实际上是分类方法

这里“逻辑”是音译, 来自逻辑函数: logistic function
也叫sigmoid function

$$g(s) = \frac{1}{1 + \exp(-s)}$$



今天的目录

■ 逻辑回归

- 分类问题
- 逻辑回归的表示
- 决策边界

■ 逻辑回归求解

- 损失函数
- 用最大似然估计 (MLE) 求参
- 用最大后验估计 (MAP) 求参
- 正则化
- 梯度下降

逻辑回归

- 把逻辑函数里的自变量替换成 $\mathbf{w}^T \mathbf{x}$

$$g(s) = \frac{1}{1 + \exp(-s)} \quad \longrightarrow$$

$$p(y = 1 | \mathbf{x}, \mathbf{w}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}}$$

阳性概率

- $h(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x})$

- 分类判断

- 如果 $P(y=1 | \mathbf{x}, \mathbf{w}) \geq 0.5$ 则阳性, 即类 1
- 否则阴性, 即类 0

- 阴性概率

- $P(y=0 | \mathbf{x}, \mathbf{w}) = 1 - P(y=1 | \mathbf{x}, \mathbf{w})$;
- $P(y=0 | \mathbf{x}, \mathbf{w}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x}}}$
- $P(y | \mathbf{x}) = \frac{1}{1 + e^{-y(\mathbf{w}^T \mathbf{x})}}$

逻辑回归的表示

- 把逻辑函数里的自变量替换成 $w^T \mathbf{x}$


$$g(s) = \frac{1}{1 + \exp(-s)}$$



$$p(y = 1 | \mathbf{x}, \mathbf{w}) = \frac{1}{1 + e^{-w^T \mathbf{x}}}$$

阳性概率

- $h(\mathbf{x}) = g(w^T \mathbf{x})$



今天的目录


■ 逻辑回归

- 分类问题
- 逻辑回归的表示
- 决策边界

■ 逻辑回归求解

- 损失函数
- 用最大似然估计 (MLE) 求参
- 用最大后验估计 (MAP) 求参
- 正则化
- 梯度下降

决策边界 (Decision Boundary)



$$\theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix} \leftarrow$$

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$


Predict " $y = 1$ " if $\frac{-3 + x_1 + x_2}{\theta^T x} \geq 0$

$\rightarrow h_{\theta}(x) = 0.5$
 $\boxed{x_1 + x_2 = 3}$

$\rightarrow \underline{x_1 + x_2 \geq 3}$

$\rightarrow x_1 + x_2 < 3$
 $y = 0$

非线性决策边界 (Decision Boundary)

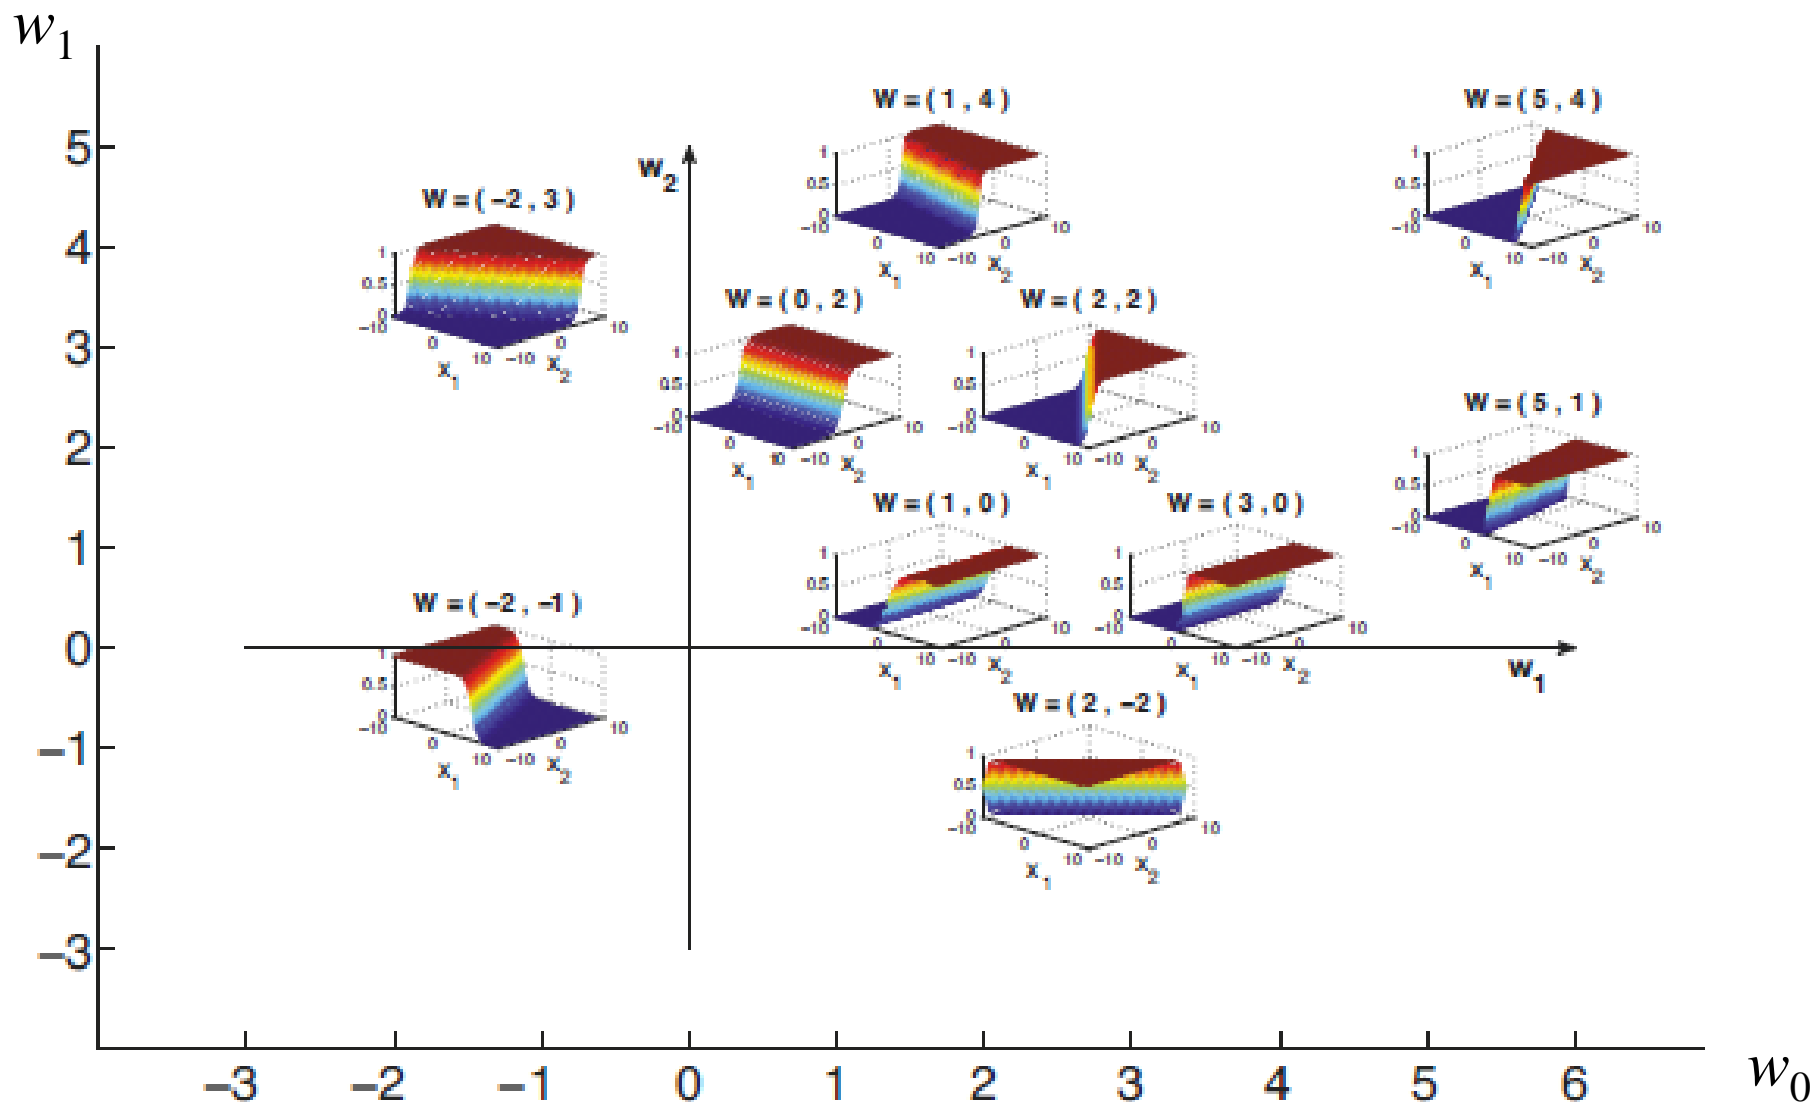


$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

Predict “ $y = 1$ ” if $-1 + x_1^2 + x_2^2 \geq 0$

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_1^2 x_2 + \theta_5 x_1^2 x_2^2 + \theta_6 x_1^3 x_2 + \dots)$$

决策边界直观理解 (Decision Boundary)



今天的目录

■ 逻辑回归

- 分类问题
- 逻辑回归的表示
- 决策边界

■ 逻辑回归求解

- 损失函数
- 用最大似然估计 (MLE) 求参
- 用最大后验估计 (MAP) 求参
- 正则化
- 梯度下降

损失函数 (Loss function / Cost function)

预测概率:

$$P(y = 1|x) = h_{\theta}(x) = \frac{1}{1 + e^{(-\theta^T x)}} = \sigma(\theta^T x) \quad (1)$$

$$P(y = 0|x) = 1 - P(y = 1|x) = 1 - h_{\theta}(x) \quad (2)$$

结合 (1) 和 (2):

$$P(y|x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y} \quad \text{y 表示标签, 取值为 0 或 1} \quad (3)$$

对给定的 m 个样本, 使用最大似然估计 (MLE):

$$L(\theta) = \prod_{i=1}^m P(y^{(i)}|x^{(i)}; \theta) = \prod_{i=1}^m (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}} \quad (6)$$

$$\longrightarrow \ell(\theta) = \log L(\theta) = \sum_{i=1}^m (y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))) \quad (7)$$

$$J(\theta) = -\frac{1}{m} \ell(\theta)$$

$J(\theta)$ 是设计的损失函数

逻辑回归的MLE

- 在 MLE 中，我们选择**最大化条件似然**的参数。条件似然 $P(Y|X, w)$ 是以训练数据中特征向量 x_i 为条件的观测值 $Y \in R^n$ 中的概率。其中， $X = [x_1, \dots, x_i, \dots, x_n] \in R^{d \times n}$ 。
- 我们选择使该函数最大化的参数，并假设对于给定的输入特征 x_i 和 w 时 y_i 之间是独立的。

$$P(y | X, w) = \prod_{i=1}^n P(y_i | x_i, w).$$

我们对上式取 \log ：

$$\begin{aligned} \log \left(\prod_{i=1}^n P(y_i | x_i, w) \right) &= - \sum_{i=1}^n \log(1 + e^{-y_i w^T x_i}) \\ \hat{w}_{MLE} &= \underset{w}{\operatorname{argmax}} - \sum_{i=1}^n \log(1 + e^{-y_i w^T x_i}) \\ &= \underset{w}{\operatorname{argmin}} \sum_{i=1}^n \log(1 + e^{-y_i w^T x_i}) \end{aligned}$$

逻辑回归的MLE

$$\hat{\mathbf{w}}_{MLE} = \underset{\mathbf{w}}{\operatorname{argmin}} \sum_{i=1}^n \log(1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i})$$

- 我们需要估计参数 w 。为了求出最小值对应的参数，可以试着求出 $\nabla_w \sum_i^n \log(1 + e^{y_i w^T x_i}) = 0$ 。
- 该方程没有闭式解。我们在负对数似然上使用梯度下降来寻找近似解：

$$\ell(\mathbf{w}) = \sum_{i=1}^n \log(1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i})$$

逻辑回归的MAP

- 在 MAP 估计中, 我们将 w 作为一个随机变量, 并可以指定它的先验分布。假设先验为: $w \sim N(0, \sigma^2 I)$ 。这是逻辑回归的高斯近似。
- 我们在 MAP 中的目标是找到对给定数据的**最大化后验**的模型参数。

$$P(w|D) = \frac{P(D|w)P(w)}{P(D)} \propto P(D|w)P(w)$$

$$\begin{aligned} P(w|D) &= P(w|X, y) \propto P(X, y|w)P(w) \\ &= P(y|X, w)P(X, w)P(w) \propto P(y|X, w)P(w) \end{aligned}$$

$$\hat{w}_{MAP} = \operatorname{argmax}_w \log(P(y|X, w)P(w))$$

$$= \operatorname{argmin}_w \sum_{i=1}^n \log(1 + e^{y_i w^T x_i}) + \lambda w^T w$$

$\lambda = \frac{1}{2\sigma^2}$ 。同样, 这个函数没有闭式解, 但我们可以负对数后验上使用梯度下降来找到最优的参数。

$$\ell(\mathbf{w}) = \sum_{i=1}^n \log(1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i}) + \lambda \mathbf{w}^T \mathbf{w}$$

今天的目录

■ 逻辑回归

- 分类问题
- 逻辑回归的表示
- 决策边界

■ 逻辑回归求解

- 损失函数
- 用最大似然估计 (MLE) 求参
- 用最大后验估计 (MAP) 求参
- 正则化
- 梯度下降

正则化 (Regularization)

基本思想


- L_2 正则:

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}))^2 + \lambda \sum_{j=1}^n \theta_j^2 \right] \quad (8)$$

- 正则化: 防止权重变得过大
- 正则化可以通过对权值的约束在一定程度上避免过拟合

正则化 (Regularization)

Example: Logistic regression




$$\rightarrow h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

(g = sigmoid function)


↖

"Underfit"



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2)$$

↖




$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \theta_6 x_1^3 x_2 + \dots)$$

↖


"Overfit"

正则化 (Regularization)


通过逻辑回归对任务进行分类



$\lambda = 1$ Good !



$\lambda = 0$ Overfitting



$\lambda = 100$ Underfitting

不同 λ 值的二分类效果

今天的目录

■ 逻辑回归

- 分类问题
- 逻辑回归的表示
- 决策边界

■ 逻辑回归求解

- 损失函数
- 用最大似然估计 (MLE) 求参
- 用最大后验估计 (MAP) 求参
- 正则化
- 梯度下降


梯度下降预览 (Gradient Descent)

损失函数 $J(\theta_0, \theta_1)$

目标 $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

概览:

- 以某个值开始 θ_0, θ_1
- 不停更新 θ_0, θ_1 来减小 $J(\theta_0, \theta_1)$
- 直到我们认为达到了最小值



逻辑回归梯度下降 (Gradient Descent)

$$J(\theta) = - \sum_{i=1}^m (y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})))$$

↓

偏导数:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \sum_i x_j^{(i)} (h_{\theta}(x^{(i)}) - y^{(i)})$$

↓

权重更新:

$$\theta_j = \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$$

总结

- 逻辑回归，一种解决分类问题的常用方法，将线性回归嵌入逻辑函数

$$g(s) = \frac{1}{1 + \exp(-s)} \quad \longrightarrow \quad p(y = 1 | \mathbf{x}, \mathbf{w}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}}$$

- $h(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x})$

■ 逻辑回归求解

- y 的概率的统一表示方法 $P(y|x; \theta) = (h_\theta(x))^y (1 - h_\theta(x))^{1-y}$ y 表示标签，取值为 0 或 1

- 损失函数

$$L(\theta) = \prod_{i=1}^m P(y^{(i)} | x^{(i)}; \theta) = \prod_{i=1}^m (h_\theta(x^{(i)}))^{y^{(i)}} (1 - h_\theta(x^{(i)}))^{1-y^{(i)}} \quad (6)$$

$$\rightarrow \ell(\theta) = \log L(\theta) = \sum_{i=1}^m (y^{(i)} \log h_\theta(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))) \quad (7)$$

$$J(\theta) = -\frac{1}{m} \ell(\theta) \quad J(\theta) \text{ 是设计的损失函数}$$

- 用梯度下降求解